xplsek03

October 19, 2024

Vítejte u prvního projektu do SUI. V rámci projektu Vás čeká několik cvičení, v nichž budete doplňovat poměrně malé fragmenty kódu (místo je vyznačeno pomocí `None` nebo `pass`). Pokud se v buňce s kódem již něco nachází, využijte/neničte to. Buňky nerušte ani nepřidávejte. Snažte se programovat hezky, ale jediná skutečně aktivně zakázaná, vyhledávaná a – i opakovaně – postihovaná technika je cyklení přes data (ať už explicitním cyklem nebo v rámci `list`/`dict` comprehension), tomu se vyhýbejte jako čert kříží a řešte to pomocí vhodných operací lineární algebry.

Až budete s řešením hotovi, vyexportujte ho ("Download as") jako PDF i pythonovský skript a ty odevzdejte **pojmenované názvem týmu** (tj. loginem vedoucího). Dbejte, aby bylo v PDF všechno vidět (nezůstal kód za okrajem stránky apod.).

U všech cvičení je uveden orientační počet řádků řešení. Berte ho prosím opravdu jako orientační, pozornost mu věnujte, pouze pokud ho významně překračujete.

[2]:
```
import numpy as np
import copy
import matplotlib.pyplot as plt
import scipy.stats
```

1 Přípravné práce

Prvním úkolem v tomto projektu je načíst data, s nimiž budete pracovat. Vybudujte jednoduchou třídu, která se umí zkonstruovat z cesty k negativním a pozitivním příkladům, a bude poskytovat: - pozitivní a negativní příklady (`dataset.pos`, `dataset.neg` o rozměrech [N, 7]) - všechny příklady a odpovídající třídy (`dataset.xs` o rozměru [N, 7], `dataset.targets` o rozměru [N])

K načítání dat doporučujeme využít `np.loadtxt()`. Netrapte se se zapouzdřováním a gettery, berte třídu jako Plain Old Data.

Načtěte trénovací (`{positives,negatives}.trn`), validační (`{positives,negatives}.val`) a testovací (`{positives,negatives}.tst`) dataset, pojmenujte je po řadě `train_dataset`, `val_dataset` a `test_dataset`.

(6 řádků)

[3]:
```
class BinaryDataset:
    def __init__(self, pos, neg):
        self.pos = np.loadtxt(pos)
        self.neg = np.loadtxt(neg)
        self.xs = np.r_[self.pos, self.neg]
```

```
        self.targets = np.r_[np.ones(len(self.pos)), np.zeros(len(self.neg))] ␣
 ↪# 0/1 binary only, jsem dement, hlavne ze to je v nazvu celou dobu

train_dataset = BinaryDataset('positives.trn', 'negatives.trn')
val_dataset = BinaryDataset('positives.val', 'negatives.val')
test_dataset = BinaryDataset('positives.tst', 'negatives.tst')

print('positives', train_dataset.pos.shape)
print('negatives', train_dataset.neg.shape)
print('xs', train_dataset.xs.shape)
print('targets', train_dataset.targets.shape)
```

```
positives (2280, 7)
negatives (6841, 7)
xs (9121, 7)
targets (9121,)
```

V řadě následujících cvičení budete pracovat s jedním konkrétním příznakem. Naimplementujte proto funkci, která vykreslí histogram rozložení pozitivních a negativních příkladů z jedné sady. Nezapomeňte na legendu, ať je v grafu jasné, které jsou které. Funkci zavoláte dvakrát, vykreslete histogram příznaku `5` – tzn. šestého ze sedmi – pro trénovací a validační data

(5 řádků)

[4]:
```
FOI = 5  # Feature Of Interest

def plot_data(poss, negs):
    plt.clf()
    plt.hist((poss, negs), label=('Pozitivni', 'Negativni'), bins=15,␣
 ↪histtype='step')
    plt.legend(loc='upper right')
    plt.ylabel('Pocet vzorku')
    plt.xlabel('Hodnota')
    plt.show()

plot_data(train_dataset.pos[:, FOI], train_dataset.neg[:, FOI])
plot_data(val_dataset.pos[:, FOI], val_dataset.neg[:, FOI])
```

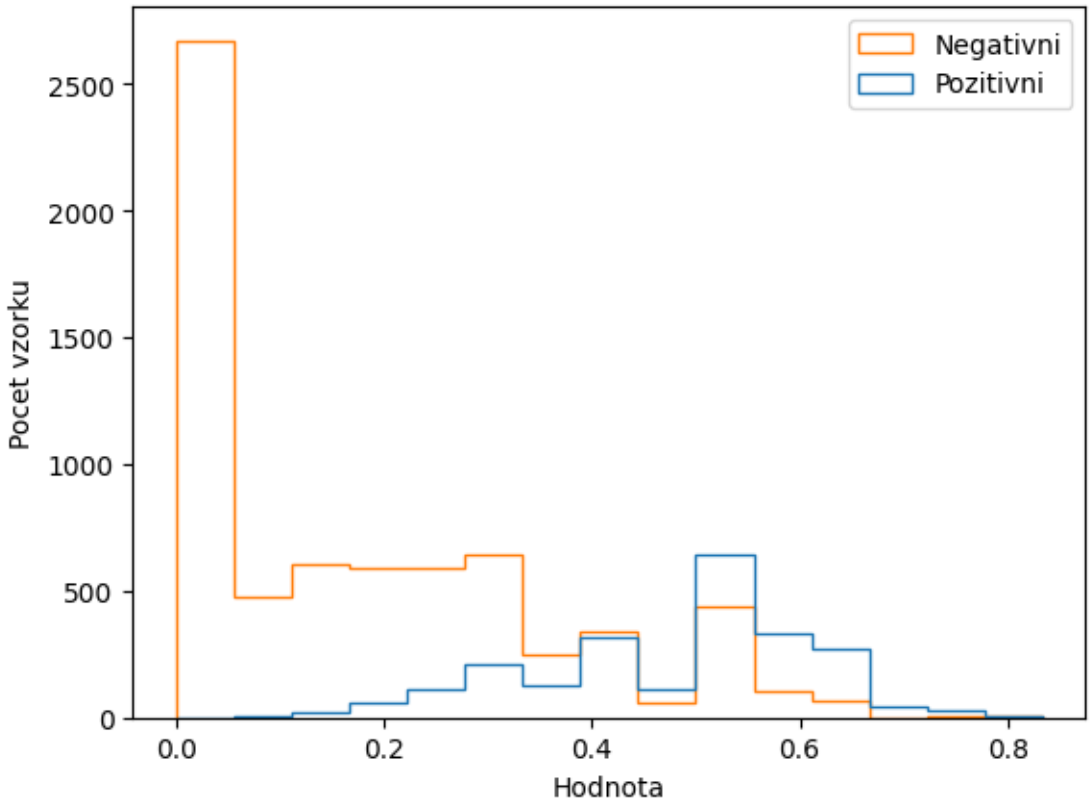
Negativni
Pozitivni
Pocet vzorku
Hodnota
0
500
1000
1500
2000
2500
0.0
0.2
0.4
0.6
0.8

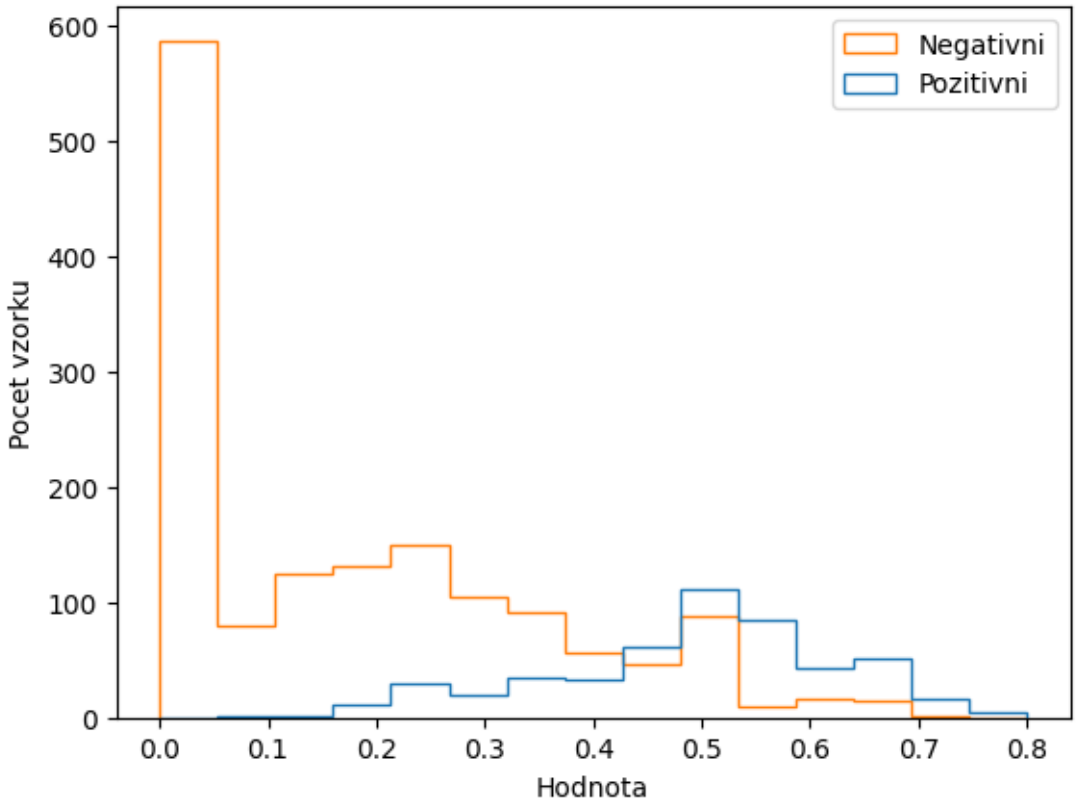

1.0.1 Evaluace klasifikátorů

Než přistoupíte k tvorbě jednotlivých klasifikátorů, vytvořte funkci pro jejich vyhodnocování. Nechť se jmenuje `evaluate` a přijímá po řadě klasifikátor, pole dat (o rozměrech [N, F]) a pole tříd ([N]). Jejím výstupem bude *přesnost* (accuracy), tzn. podíl správně klasifikovaných příkladů.

Předpokládejte, že klasifikátor poskytuje metodu `.prob_class_1(data)`, která vrací pole posteriorních pravděpodobností třídy 1 pro daná data. Evaluační funkce bude muset provést tvrdé prahování (na hodnotě 0.5) těchto pravděpodobností a srovnání získaných rozhodnutí s referenčními třídami. Využijte fakt, že `numpy`ovská pole lze mj. porovnávat se skalárem.

(3 řádky)

[5]:
```
def evaluate(classifier, inputs, targets):
    result = classifier.prob_class_1(inputs) > 0.5
    return np.mean(result == targets)  # prumer z vysledku prahovani, porovnani␣
 ↪s referencnimi tridami

class Dummy:
    def prob_class_1(self, xs):
        return np.asarray([0.2, 0.7, 0.7])  # posteriorni = P(A|H)
```

```
print(evaluate(Dummy(), None, np.asarray([0, 0, 1])))  # should be 0.66
```

```
0.6666666666666666
```

1.0.2 Baseline

Vytvořte klasifikátor, který ignoruje vstupní data. Jenom v konstruktoru dostane třídu, kterou má dávat jako tip pro libovolný vstup. Nezapomeňte, že jeho metoda `.prob_class_1(data)` musí vracet pole správné velikosti.

(4 řádky)

[6]:
```
class PriorClassifier:
    def __init__(self, val):
        self.default_val = val

    def prob_class_1(self, xs):
        return np.full(xs.size, self.default_val)

baseline = PriorClassifier(0)
val_acc = evaluate(baseline, val_dataset.xs[:, FOI], val_dataset.targets)
print('Baseline val acc:', val_acc)
```

```
Baseline val acc: 0.75
```

2 Generativní klasifikátory

V této části vytvoříte dva generativní klasifikátory, oba založené na Gaussovu rozložení pravděpodobnosti.

Začněte implementací funce, která pro daná 1-D data vrátí Maximum Likelihood odhad střední hodnoty a směrodatné odchylky Gaussova rozložení, které data modeluje. Funkci využijte pro natrénovaní dvou modelů: pozitivních a negativních příkladů. Získané parametry – tzn. střední hodnoty a směrodatné odchylky – vypíšete.

(1 řádek)

[7]:
```
def mle_gauss_1d(data):
    return np.mean(data), np.std(data)  # parametry max likelihood gausse

mu_pos, std_pos = mle_gauss_1d(train_dataset.pos[:, FOI])
mu_neg, std_neg = mle_gauss_1d(train_dataset.neg[:, FOI])

print('Pos mean: {:.2f} std: {:.2f}'.format(mu_pos, std_pos))
print('Neg mean: {:.2f} std: {:.2f}'.format(mu_neg, std_neg))
```

```
Pos mean: 0.48 std: 0.13
Neg mean: 0.17 std: 0.18
```

Ze získaných parametrů vytvořte `scipy`ovská gaussovská rozložení `scipy.stats.norm`. S využitím jejich metody `.pdf()` vytvořte graf, v němž srovnáte skutečné a modelové rozložení pozitivních a negativních příkladů. Rozsah x-ové osy volte od -0.5 do 1.5 (využijte `np.linspace`) a u volání `plt.hist()` nezapomeňte nastavit `density=True`, aby byl histogram normalizovaný a dal se srovnávat s modelem.

(2 + 8 řádků)

[8]:
```
pos = scipy.stats.norm(loc=mu_pos, scale=std_pos)
neg = scipy.stats.norm(loc=mu_neg, scale=std_neg)
space = np.linspace(-0.5, 1.5, 150)

plt.plot(space, pos.pdf(space), label='Pozitivni - z modelu')
plt.plot(space, neg.pdf(space), label='Negativni - z modelu')
plt.hist((train_dataset.pos[:, FOI], train_dataset.neg[:, FOI]),␣
 ↪label=('Pozitivni - tren. data', 'Negativni - tren. data'), alpha=0.5,␣
 ↪histtype='step', density=True)
plt.legend(loc='upper right')
plt.ylabel('Hustota pravdepodobnosti')
plt.show()
```

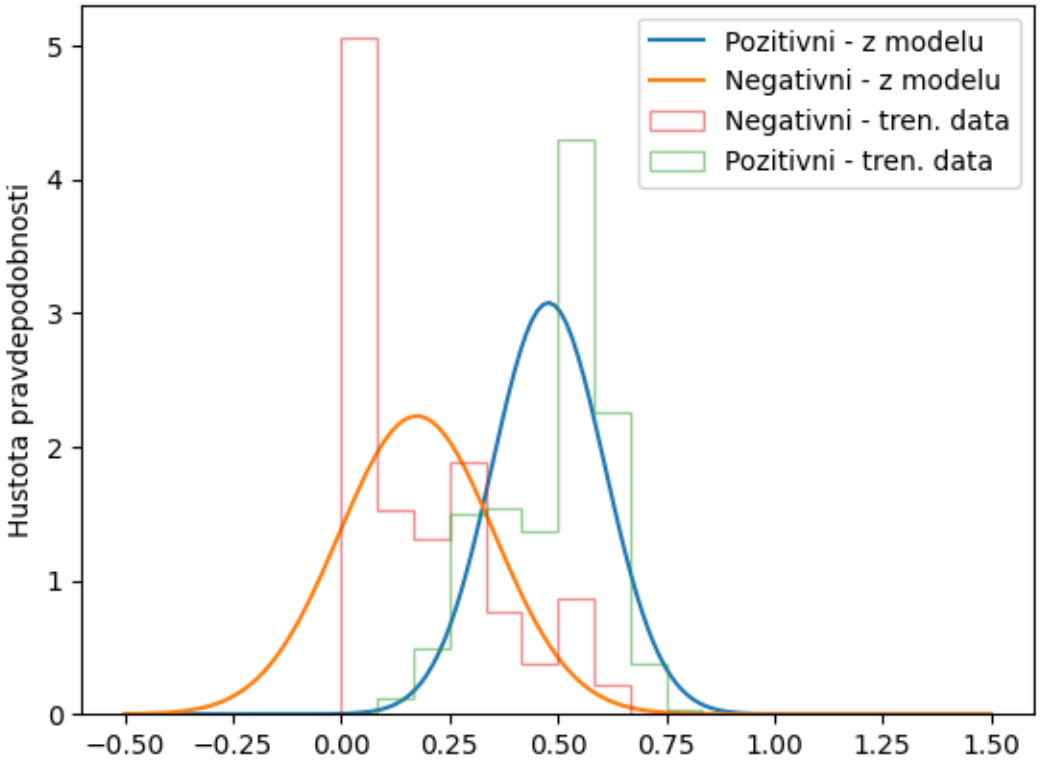

Naimplementujte binární generativní klasifikátor. Při konstrukci přijímá dvě rozložení poskytující metodu `.pdf()` a odpovídající apriorní pravděpodobnost tříd. Dbejte, aby Vám uživatel nemohl

zadat neplatné apriorní pravděpodobnosti. Jako všechny klasifikátory v tomto projektu poskytuje metodu `prob_class_1()`.

(9 řádků)

[9]:
```
class GenerativeClassifier2Class:

    def __init__(self, rozl_pos, rozl_neg, prob_pos, prob_neg):  # apriorni:␣
↪P(A) na prave strane, pravdepodobnost tridy je pravdepodobnost s jakou spada␣
↪do tridy P(A), P(G)
        assert 0 <= prob_pos <= 1 and 0 <= prob_neg <= 1, 'prob_pos / prob_neg␣
↪invalid'
        self.rozl_pos = rozl_pos
        self.rozl_neg = rozl_neg
        self.prob_pos = prob_pos
        self.prob_neg = prob_neg

    def prob_class_1(self, xs):
        pos = self.rozl_pos.pdf(xs) * self.prob_pos  # P(A|H)*P(A)
        neg = self.rozl_neg.pdf(xs) * self.prob_neg  # P(G|H)*P(G)
        return pos / (pos + neg)  # P(A|H)*P(A)/( P(A|H)*P(A) + P(G|H)*P(G) =>␣
↪df. P(H) )
```

Nainstancujte dva generativní klasifikátory: jeden s rovnoměrnými priory a jeden s apriorní pravděpodobností 0.75 pro třídu 0 (negativní příklady). Pomocí funkce `evaluate()` vyhodnotíte jejich úspěšnost na validačních datech.

(2 řádky)

[10]:
```
classifier_flat_prior = GenerativeClassifier2Class(pos, neg, 0.5, 0.5)
classifier_full_prior = GenerativeClassifier2Class(pos, neg, 0.25, 0.75)

print('flat:', evaluate(classifier_flat_prior, val_dataset.xs[:, FOI],␣
↪val_dataset.targets))
print('full:', evaluate(classifier_full_prior, val_dataset.xs[:, FOI],␣
↪val_dataset.targets))
```

```
flat: 0.809
full: 0.8475
```

Vykreslete průběh posteriorní pravděpodobnosti třídy 1 jako funkci příznaku 5, opět v rozsahu <-0.5; 1.5> pro oba klasifikátory. Do grafu zakreslete i histogramy rozložení trénovacích dat, opět s `density=True` pro zachování dynamického rozsahu.

(8 řádků)

[11]:
```
space = np.linspace(-0.5, 1.5)
plt.plot(space, classifier_flat_prior.prob_class_1(space),␣
↪label='classifier_flat_prior')
```

```
plt.plot(space, classifier_full_prior.prob_class_1(space),␣
 ↪label='classifier_full_prior')
plt.hist((train_dataset.pos[:, FOI], train_dataset.neg[:, FOI]),␣
 ↪label=('Pozitivni - tren. data', 'Negativni - tren. data'), histtype='step',␣
 ↪density=True)
plt.legend(loc='upper right')
plt.show()
```

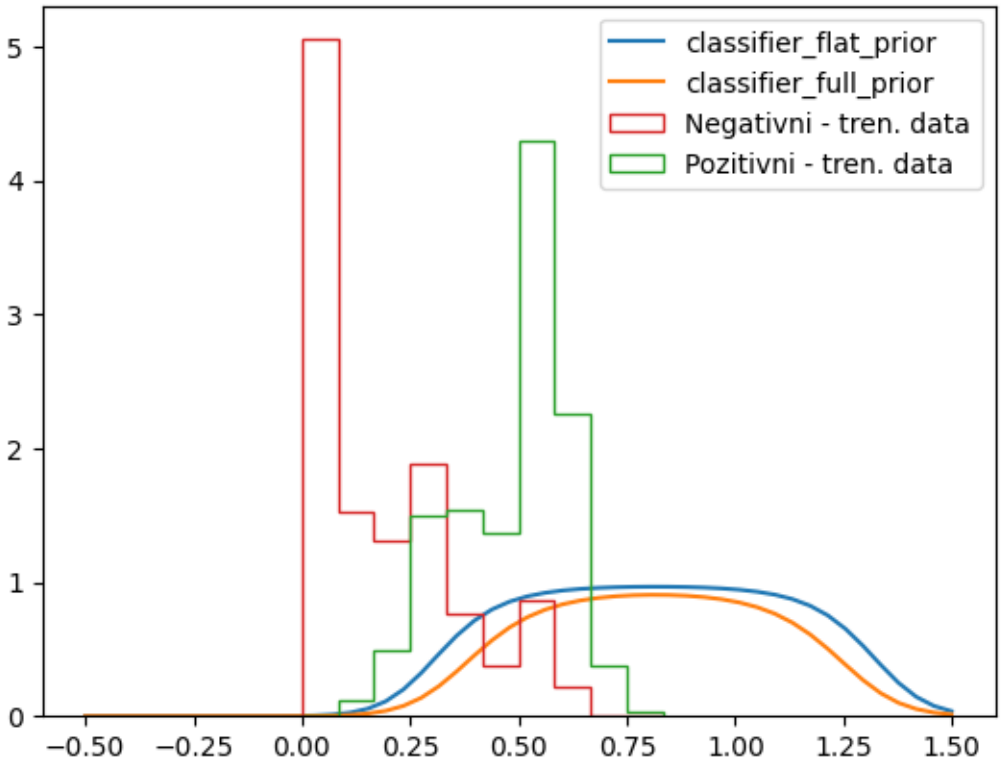

3 Diskriminativní klasifikátory

V následující části budete pomocí (lineární) logistické regrese přímo modelovat posteriorní pravděpodobnost třídy 1. Modely budou založeny čistě na NumPy, takže nemusíte instalovat nic dalšího. Nabitějších toolkitů se dočkáte ve třetím projektu.

[12]:
```
def logistic_sigmoid(x):  # normalizuje na (0;1)
    return np.exp(-np.logaddexp(0, -x))

def binary_cross_entropy(probs, targets):  # vypocita kvalitu modelu na␣
 ↪testovacich datech
    return np.sum(-targets * np.log(probs) - (1-targets)*np.log(1-probs))
```

```
class LogisticRegressionNumpy:
    def __init__(self, dim):
        self.w = np.array([0.0] * dim)  # tohle je param vektor [w1;..wn]
        self.b = np.array([0.0])  # tohle je param w0

    def prob_class_1(self, x):  # vrati pravdepodobnost tridy pro sloupec x
        return logistic_sigmoid(x @ self.w + self.b)  # maticovy nasobeni␣
 ↪vektoru [1,x][w0,w1]
```

Diskriminativní klasifikátor očekává, že dostane vstup ve tvaru `[N, F]`. Pro práci na jediném příznaku bude tedy zapotřebí vyřezávat příslušná data v správném formátu (`[N, 1]`). Doimplementujte třídu `FeatureCutter` tak, aby to zařizovalo volání její instance. Který příznak se použije, nechť je konfigurováno při konstrukci.

Může se Vám hodit `np.newaxis`.

(2 řádky)

[13]:
```
class FeatureCutter:
    def __init__(self, fea_id):
        self.fea_id = fea_id

    def __call__(self, x):
        return x[:, self.fea_id][:, np.newaxis]
```

Dalším krokem je implementovat funkci, která model vytvoří a natrénuje. Jejím výstupem bude (1) natrénovaný model, (2) průběh trénovací loss a (3) průběh validační přesnosti. Neuvažujte žádné minibatche, aktualizujte váhy vždy na celém trénovacím datasetu. Po každém kroku vyhodnoťte model na validačních datech. Jako model vracejte ten, který dosáhne nejlepší validační přesnosti. Jako loss použijte binární cross-entropii a logujte průměr na vzorek. Pro výpočet validační přesnosti využijte funkci `evaluate()`. Oba průběhy vracejte jako obyčejné seznamy.

(cca 11 řádků)

[14]:
```
def train_logistic_regression(nb_epochs: int, lr: float, in_dim: int,␣
 ↪fea_preprocessor: FeatureCutter):
    model = LogisticRegressionNumpy(in_dim)
    best_model = copy.deepcopy(model)
    losses = []
    accuracies = []

    train_X = fea_preprocessor(train_dataset.xs)  # vrat X z datasetu co␣
 ↪trenujes
    train_t = train_dataset.targets  # vektor trenovacich trid

    val_X = fea_preprocessor(val_dataset.xs)  # tohle jsou data na kterych to␣
 ↪mas validovat
    val_t = val_dataset.targets  # vektor validacnich trid
```

```
    best_evaluation = evaluate(best_model, val_X, val_t)  # zatim nejlepsi␣
↪vyhodnoceni modelu
    lr /= len(train_X)  # normalizuj learning rate, ma to tak v demu

    for _ in range(nb_epochs):
        xnw = model.prob_class_1(train_X)  # vraci xnw v sigmoidu
        grad = (xnw - train_t).dot(train_X)  # hodnota gradientu, np.sum tam␣
↪byt nemusi
        model.w -= lr * grad  # regrese po gradientu, v demu
        model.b -= lr * np.sum(xnw - train_t)  # w0, v demu

        losses.append(binary_cross_entropy(xnw, train_t) / len(train_t))  #␣
↪uloz loss jako prumer na vzorek

        # proved vyhodnoceni klasifikatoru na validacnich datech
        evaluation = evaluate(model, val_X, val_t)
        accuracies.append(evaluation)

        if evaluation >= best_evaluation:
            best_evaluation = evaluation
            best_model = copy.deepcopy(model)

    return best_model, losses, accuracies
```

Funkci zavolejte a natrénujte model. Uveďte zde parametry, které vám dají slušný výsledek. Měli byste dostat přesnost srovnatelnou s generativním klasifikátorem s nastavenými priory. Neměli byste potřebovat víc, než 100 epoch. Vykreslete průběh trénovací loss a validační přesnosti, osu x značte v epochách.

V druhém grafu vykreslete histogramy trénovacích dat a pravděpodobnost třídy 1 pro x od -0.5 do 1.5, podobně jako výše u generativních klasifikátorů.

(1 + 5 + 8 řádků)

[15]:
```
disc_fea5, losses, accuracies = train_logistic_regression(100, 6, 1,␣
↪FeatureCutter(FOI))

print('w', disc_fea5.w.item(), 'b', disc_fea5.b.item())

plt.plot(losses, label='Loss funkce')
plt.plot(accuracies, label='Presnost')
plt.xlabel('Epocha')
plt.legend(loc='center right')
plt.show()

space = np.linspace(-0.5, 1.5)
plt.plot(space, disc_fea5.prob_class_1(space[:, np.newaxis]),␣
↪label='Pravdepodobnost tridy 1')
```

```
plt.hist((train_dataset.pos[:, FOI], train_dataset.neg[:, FOI]),␣
 ↪label=('Pozitivni - tren. data', 'Negativni - tren. data'), histtype='step',␣
 ↪density=True)
plt.legend(loc='upper right')
plt.show()

print('disc_fea5:', evaluate(disc_fea5, val_dataset.xs[:, FOI][:, np.newaxis],␣
 ↪val_dataset.targets))
```

```
w 8.029419780006648 b -3.707017949037386
```

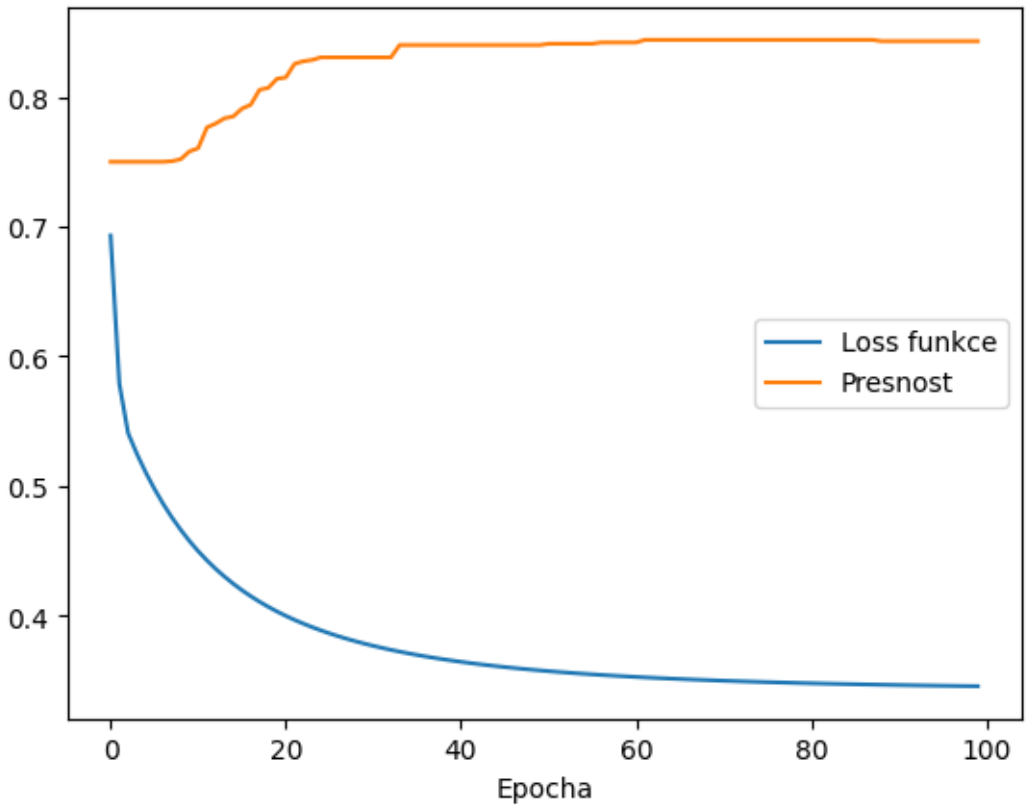

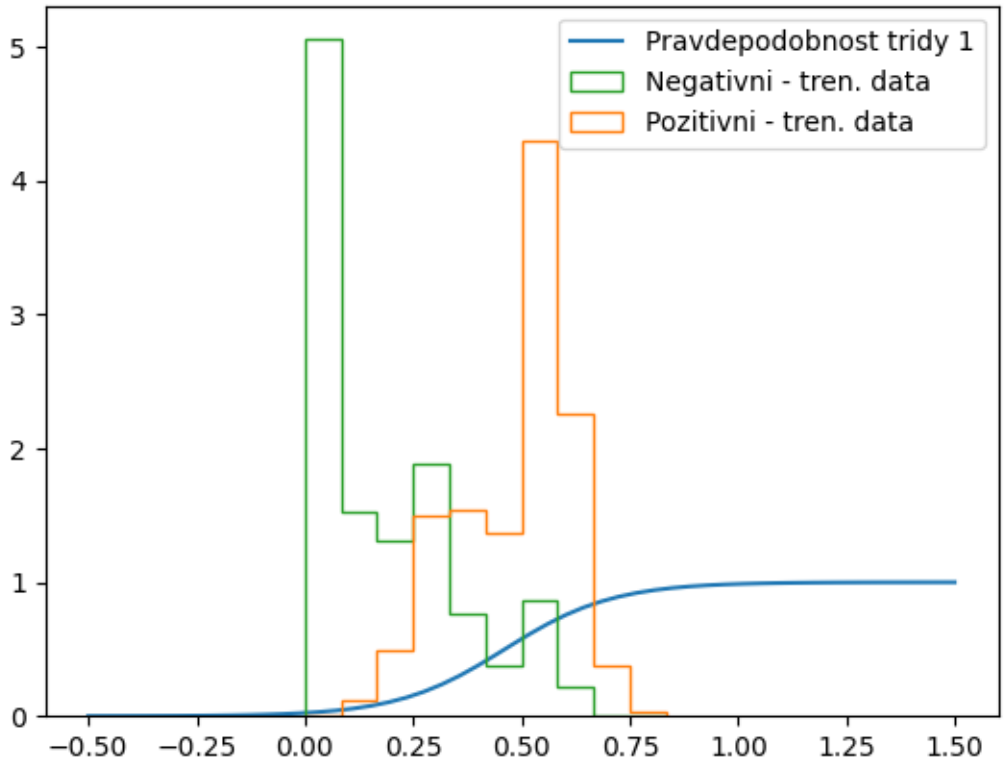


```
disc_fea5: 0.844
```

3.1 Všechny vstupní příznaky

V posledním cvičení natrénujete logistickou regresi, která využije všechn sedm vstupních příznaků. Zavolejte funkci z předchozího cvičení, opět vykreslete průběh trénovací loss a validační přesnosti. Měli byste se dostat nad 90 % přesnosti.

Může se Vám hodit `lambda` funkce.

(1 + 5 řádků)

[16]:
```
disc_full_fea, losses, accuracies = train_logistic_regression(300, 0.003, 7,␣
↪lambda x: x)  # https://stackoverflow.com/a/22738440
plt.plot(losses, label='Loss')
plt.plot(accuracies, label='Presnost')
plt.xlabel('Epocha')
plt.legend(loc='center right')
plt.show()
```

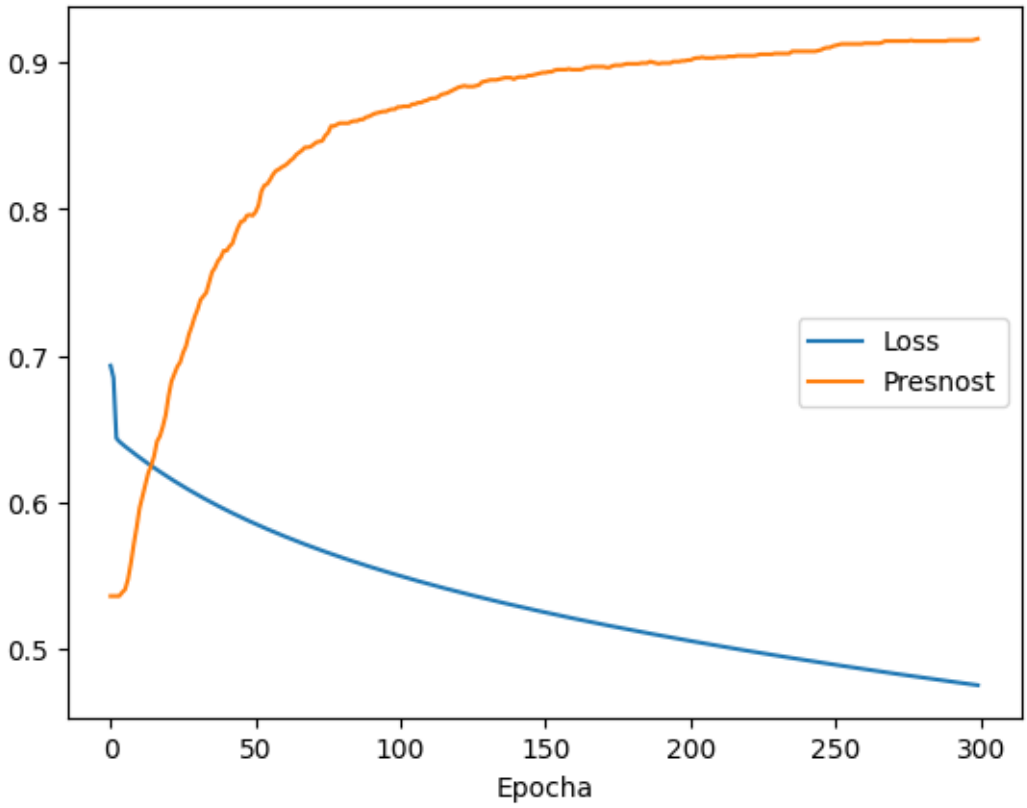

4 Závěrem

Konečně vyhodnoťte všech pět vytvořených klasifikátorů na testovacích datech. Stačí doplnit jejich názvy a předat jim odpovídající příznaky. Nezapomeňte, že u logistické regrese musíte zopakovat formátovací krok z `FeatureCutteru`.

[17]:
```
xs_full = test_dataset.xs
xs_foi = test_dataset.xs[:, FOI]
targets = test_dataset.targets

print('Baseline:', evaluate(baseline, xs_foi, targets))
print('Generative classifier (w/o prior):', evaluate(classifier_flat_prior,␣
 ↪xs_foi, targets))
print('Generative classifier (correct):', evaluate(classifier_full_prior,␣
 ↪xs_foi, targets))
print('Logistic regression:', evaluate(disc_fea5, xs_foi[:, np.newaxis],␣
 ↪targets))
print('logistic regression all features:', evaluate(disc_full_fea, xs_full,␣
 ↪targets))
```

```
Baseline: 0.75
Generative classifier (w/o prior): 0.8
Generative classifier (correct): 0.847
Logistic regression: 0.852
logistic regression all features: 0.9135
```

Blahopřejeme ke zvládnutí projektu! Nezapomeňte (1) spustit celý notebook načisto (Kernel -> Restart & Run all), (2) zkontrolovat, že všechny výpočty prošly podle očekávání, a (3) před odevzdáním pojmenovat soubory loginem vedoucího týmu.

Mimochodem, vstupní data nejsou synteticky generovaná. Nasbírali jsme je z baseline řešení historicky prvního SUI projektu; vaše klasifikátory v tomto projektu predikují, že daný hráč vyhraje dicewars, takže by se daly použít jako heuristika pro ohodnocování listových uzlů ve stavovém prostoru hry. Pro představu, data jsou z pozic pět kol před koncem partie pro daného hráče. Poskytnuté příznaky popisují globální charakteristiky stavu hry jako je například poměr délky hranic předmětného hráče k ostatním hranicím. Nejeden projekt v ročníku 2020 realizoval požadované "strojové učení" v agentovi hrajicím dicewars kopií domácí úlohy, která byla předchůdkyní tohoto projektu.

[ ]: